

ML۴RE - یادگیری ماشین برای مهندسی نیازمندی‌ها

چکیده

مقدمه: تحقیقات در زمینه یادگیری ماشین برای مهندسی نیازمندی‌ها (ML۴RE) به تدریج توجه بیشتری از سوی محققان و عملی‌کنندگان به خود جلب کرده است. اگرچه تحقیقات پیشگامانه پتانسیل استفاده از تکنیک‌های یادگیری ماشین برای بهبود فرآیندهای مهندسی نیازمندی‌ها را نشان داده‌اند، اما یک مرور نظام‌مند و جامع از ادبیات علمی که دیدگاه صنعتی را نیز در بر گیرد، در دانشگاه‌ها وجود ندارد. به‌ویژه، هیچ‌یک از مرورهای موجود در زمینه ML۴RE به ادبیات خاکستری که عمدتاً از منابع عملی‌کنندگان منشأ می‌گیرد و بازتاب‌دهنده مسائل و چالش‌های واقعی در عمل است، توجه نکرده‌اند.

هدف: در این مقاله، ما یک بررسی نظام‌مند از انتشارات علمی در زمینه ML۴RE انجام می‌دهیم و آن را با نظرات عملی‌کنندگان از Stack Overflow تکمیل می‌کنیم تا یک مرور جامع از ادبیات ارائه دهیم. هدف تحقیق ما ارائه یک دیدگاه جامع از پیشرفت‌های کنونی در تحقیقات ML۴RE، بیان سوالات و چالش‌های اصلی در عمل مهندسی نیازمندی‌ها، درک فاصله بین تحقیق و عمل، و ارائه بینش‌های خود درباره چگونگی توسعه عملی این حوزه دانشگاهی در آینده است.

روش: ما به صورت نظام‌مند ۲۰۷ مقاله علمی در زمینه ML۴RE از سال ۲۰۱۰ تا ۲۰۲۲ را بررسی کردیم و همچنین ۳۷۵ سوال مرتبط با مهندسی نیازمندی‌ها در Stack Overflow و پاسخ‌های مربوطه را تحلیل کردیم. تحلیل ما شامل روندها، فعالیت‌ها و وظایف متمرکز بر مهندسی نیازمندی‌ها، راه‌حل‌های به‌کاررفته و داده‌های مرتبط بود. در نهایت، یک تحلیل مشترک انجام دادیم و نتایج هر دو بخش را با هم مقایسه کردیم. نتایج: بر اساس نتایج آماری از ادبیات جمع‌آوری‌شده، ما یک نقشه راه علمی را خلاصه کرده و تفاوت‌ها را تحلیل کردیم و توصیه‌های پژوهشی ارائه دادیم. پیشنهادات ما شامل توسعه دستیاران هوشمند پاسخگویی به سوالات با استفاده از مدل‌های زبان بزرگ، ادغام یادگیری ماشین در ابزارهای صنعتی و ترویج همکاری بین دانشگاه و صنعت است.

نتیجه‌گیری: این مطالعه با ارائه یک دیدگاه جامع از ML۴RE، بیان تفاوت‌های بین تحقیق و عمل، و پیشنهاد راه‌حل‌های عملی برای پر کردن شکاف بین دانشگاه و صنعت، به پیشرفت این حوزه کمک می‌کند.

۱ مقدمه

مهندسی نیازمندی‌ها (RE) یک مرحله اساسی در مراحل اولیه مهندسی نرم‌افزار (SE) است. اگرچه پژوهشگران به طور مستمر در حال بررسی روش‌ها و تکنیک‌هایی برای تسهیل فرآیندهای نیازمندی هستند، اما کل فرآیند مهندسی نیازمندی‌ها همچنان نیاز به تلاش دستی زیادی دارد (مثلاً استخراج نیازمندی‌های ذی‌نفعان از طریق مصاحبه یا طبقه‌بندی نیازمندی‌ها بر اساس یک طبقه‌بندی خاص). دلیل اصلی این موضوع این است که فعالیت‌های RE معمولاً نیاز به دانش عمیق حوزه و مهارت‌های تحلیل پیشرفته دارند که به طور کامل قابل اتوماسیون نیست.

در سال‌های اخیر، توسعه سریع فناوری یادگیری ماشین (ML) با بهبود قدرت محاسباتی تحریک شده است. کاربردهای موفق ML در زمینه‌هایی مانند پردازش زبان طبیعی، شناسایی تصویر و داده‌کاوی فرصت‌هایی را برای استفاده از تکنیک‌های ML در زمینه RE فراهم کرده است. استفاده از فناوری ML در RE یک رویکرد هوشمندانه‌تر و کارآمدتر برای مدیریت داده‌های نیازمندی‌ها ارائه می‌دهد. به عنوان مثال، ML می‌تواند در طبقه‌بندی خودکار نیازمندی‌ها کمک کند زیرا می‌تواند اطلاعات بالقوه نیازمندی‌ها را خلاصه کند.

علاوه بر این، با توسعه سریع تکنیک‌های اطلاعاتی، کار و زندگی روزمره ما دیجیتالی می‌شوند. در نتیجه، داده‌های مرتبط با نیازمندی‌ها بیشتر و بیشتر دیجیتالی و به‌طور عمومی در دسترس قرار می‌گیرند، که پژوهش در زمینه یادگیری ماشین برای مهندسی نیازمندی‌ها (ML۴RE) را ترویج می‌کند. به عنوان مثال، بررسی‌های کاربران از برنامه‌های موبایلی به طور گسترده‌ای برای استخراج نیازمندی‌های کاربران مورد بررسی قرار گرفته‌اند. تحقیقات قبلی ML۴RE را مورد بررسی قرار داده‌اند. اقبال و همکاران [۲] یک بررسی برای به‌دست‌آوردن نمای کلی از چگونگی کمک تکنیک‌های ML به فعالیت‌های RE انجام دادند. علاوه بر این، زمانی و همکاران [۳] یک مطالعه نگاشت از کاربردهای ML در RE انجام دادند و ۶۵ مقاله را برای

ارزیابی اثربخشی ML در اتوماسیون وظایف RE تحلیل کردند. کارهای آن‌ها بر کل فرآیند RE متمرکز بود و نحوه تأثیرگذاری و تسهیل تکنیک‌های ML در مراحل مختلف را روشن کردند.

به علاوه، برخی تحقیقات به فعالیت‌ها یا وظایف خاص RE می‌پردازند. به عنوان مثال، لیم و همکاران [۴] رویکردهای پیشرفته فعلی برای استخراج نیازمندی‌های مبتنی بر داده از منابع داده پویا را بررسی کردند. ما متوجه شدیم که این مطالعات عمدتاً بر انتشارات علمی متمرکز بوده و از ادغام بینش‌های حاصل از منابع ادبیات خاکستری، مانند وبلاگ‌ها و انجمن‌های صنعتی غافل بوده‌اند.

بر خلاف انتشارات علمی که عمدتاً توسط پژوهشگران منتشر می‌شوند، ادبیات خاکستری به‌طور مداوم توسط عملی‌کنندگان تولید می‌شود و بر "وضعیت عمل" نور می‌تاباند [۵]. همان‌طور که در [۶] اشاره شده، ادغام ادبیات خاکستری در مرورهای نظام‌مند ادبیات می‌تواند فاصله بین پژوهش‌های علمی و عملی را پر کند و دیدگاه جامع‌تری از چالش‌ها و راه‌حل‌ها ارائه دهد.

اگرچه تعداد مرورهای نظام‌مند ادبیات که ادبیات خاکستری را در مطالعات SE در نظر گرفته‌اند در حال افزایش است [۷، ۸]، اما در RE به اندازه کافی رایج نیستند. برای پر کردن این شکاف در زمینه RE، این مقاله قصد دارد یک مرور نظام‌مند از ادبیات در زمینه ML۴RE انجام دهد که با بینش‌های حاصل از ادبیات خاکستری منابع شده از Overflow Stack تکمیل شود.

هدف این مرور ادبیات سه بخشی است. بخش سفید شامل مرور ۲۰۷ مقاله منتشر شده بین سال‌های ۲۰۱۰ تا ۲۰۲۲ است که به‌طور خاص بر ML۴RE متمرکز است. در همین حال، بخش خاکستری شامل تحلیل ۳۷۵ سوال و پاسخ‌های مربوطه جمع‌آوری شده از مباحث Overflow Stack درباره فعالیت‌های RE در همان دوره است. در نهایت، تحلیل مشترک ما شامل مقایسه نتایج این دو بخش برای تشخیص شباهت‌ها و تفاوت‌های آن‌ها است. ما روندها، فعالیت‌های RE، وظایف RE، راه‌حل‌ها و داده‌های موجود در ادبیات را تحلیل می‌کنیم.

نتایج تحقیق نشان می‌دهد که هر دو بخش به تحلیل RE و مستندسازی نیازمندی‌ها علاقه‌مند هستند. فراتر از شباهت‌ها، بخش سفید تمایل به تمرکز بر استخراج نیازمندی‌ها دارد، در حالی که بخش خاکستری بیشتر بر مدیریت نیازمندی‌ها تأکید دارد. بخش سفید استفاده از تکنولوژی‌های ML مانند CNN SVM و BERT را برجسته می‌کند. در مقابل، بخش خاکستری بیشتر بر ابزارهایی مانند Jira TFS، Microsoft و DOORS Rational IBM و تکنیک‌های ML مانند TF-IDF POS، LDA و شبکه‌های عصبی تکیه دارد. علاوه بر این، بخش خاکستری توجه ویژه‌ای به داستان کاربر و مورد استفاده دارد که در بخش سفید نسبتاً کمتر مورد بررسی قرار گرفته است.

بر اساس این یافته‌ها، ما یک نقشه راه علمی خلاصه کرده و تحلیل دقیقی از تفاوت‌های بین بخش سفید و خاکستری ارائه می‌دهیم. سپس پیشنهادات پژوهشی ارائه می‌دهیم، از جمله توسعه دستیاران هوشمند پاسخگویی به سوالات با استفاده از مدل‌های زبان بزرگ و ادغام یادگیری ماشین در ابزارهای صنعتی. همچنین، همکاری بیشتر بین دانشگاه و صنعت را برای درک عمیق‌تر مشکلات پژوهشی واقعی و داده‌ها تشویق می‌کنیم.

در خلاصه، این مقاله چهار کمک اصلی را ارائه می‌دهد. اولاً، یک نمای جامع از وضعیت فعلی پژوهش‌های ML۴RE ارائه می‌دهیم. دوماً، شرایط واقعی عملی‌کنندگان RE را از طریق ادبیات خاکستری حاصل از Overflow Stack بررسی می‌کنیم. سوماً، فاصله بین پژوهش و عمل در حوزه ML۴RE را به‌ویژه در زمینه‌هایی که کمتر مورد توجه پژوهشگران قرار گرفته‌اند، برجسته می‌کنیم. و در نهایت، برای پر کردن فاصله بین صنعت و دانشگاه، پیشنهادات پژوهشی عملی در ML۴RE ارائه می‌دهیم.

در بخش‌های باقی‌مانده این مقاله، کارهای مرتبط را در بخش ۲ ارائه می‌دهیم. بخش ۳ پروتکل تحقیق برای مرور نظام‌مند ادبیات ما را ارائه می‌دهد. در سه بخش بعدی، نتایج این بررسی و پاسخ به سوالات پژوهشی را ارائه می‌دهیم. بخش ۴ نتایج بخش سفید، بخش ۵ بر بخش خاکستری تمرکز می‌کند و بخش ۶ نتایج تحلیل مشترک را ارائه می‌دهد. بر اساس نتایج، در بخش ۷ به بحث پرداخته و چندین پیشنهاد ارائه می‌دهیم. بخش ۸ شامل تحلیل تهدیدات به اعتبار این بررسی است. در نهایت، مقاله را در بخش ۹ نتیجه‌گیری می‌کنیم.

۲ کارهای مرتبط

کارهای مرتبط با بررسی ادبیات ما در حوزه یادگیری ماشین برای مهندسی نیازمندی‌ها (ML۴RE) از دو منبع مختلف به دست آمده است. مجموعه اول شامل بررسی‌های ادبیات مرتبط با ML۴RE می‌باشد. مجموعه دوم شامل بررسی‌های سیستماتیک ادبیات در حوزه مهندسی نرم‌افزار (SE) است. در دو زیربخش پیش رو، جزئیات کارهای مرتبط از این دو منبع را به طور دقیق ارائه خواهیم داد.

۱.۲ بررسی‌های ادبیات در مورد یادگیری ماشین برای مهندسی نیازمندی‌ها (MLFRE)

در این بخش، یک مجموعه از بررسی‌های ادبیات مرتبط با یادگیری ماشین برای مهندسی نیازمندی‌ها (MLFRE) را ارائه می‌دهیم. ما چندین بررسی ادبیات را پیدا کرده‌ایم، برخی به کلیه فرآیند مهندسی نیازمندی‌ها می‌پردازند، در حالی که برخی دیگر بر روی فعالیت‌ها یا وظایف خاص مهندسی نیازمندی‌ها تمرکز دارند. بنابراین، این زیربخش به دو بخش تقسیم شده است تا این کارها را به تفصیل معرفی کند.

۱.۱.۲ فرآیند کامل مهندسی نیازمندی‌ها

دو مقاله به کلیه فرآیند مهندسی نیازمندی‌ها متمرکز شده‌اند و یک بررسی کلی از نحوه کاربرد تکنیک‌های یادگیری ماشین در مراحل مختلف مهندسی نیازمندی‌ها ارائه داده‌اند. در مقاله Iqbal و همکاران [۲]، بررسی‌ای بر روی مقالات تحقیقاتی انجام شده است تا چگونگی کمک یادگیری ماشین به مهندسی نیازمندی‌ها را بررسی کند. آن‌ها تأثیر یادگیری ماشین را در پنج مرحله اصلی مهندسی نیازمندی‌ها مشاهده کرده و مسائل خاصی که توسط یادگیری ماشین حل شده‌اند، ویژگی‌ها، الگوریتم‌های ML و مجموعه داده‌ها را بررسی کرده‌اند. با این حال، مقالاتی که آن‌ها بررسی کردند از یک فرآیند جستجوی سیستماتیک به دست نیامده بودند و بنابراین، نتیجه‌گیری‌های به دست آمده ممکن است سیستماتیک و جامع نباشد.

Zamani و همکاران [۳] یک مطالعه نگاشتی از کاربردهای یادگیری ماشین در مهندسی نیازمندی‌ها انجام دادند، با تجزیه و تحلیل ۶۵ مقاله برای ارزیابی کارایی یادگیری ماشین در اتوماسیون وظایف مهندسی نیازمندی. این مطالعه تکنیک‌ها، چالش‌ها، مجموعه داده‌ها و معیارهای ارزیابی این مطالعات را شناسایی می‌کند. مقایسه با بررسی جامع ما، این مقاله بیشتر بر جنبه‌های تجربی یادگیری ماشین در مهندسی نیازمندی‌ها تمرکز دارد و بینش‌های خاصی را در کارآمدی عملی ML در این زمینه ارائه می‌دهد. علاوه بر این، مقاله Zhao و همکاران [۹] بر روی NLP۴RE تمرکز داشتند، با تحلیل ۴۰۴ مطالعه برای درک کاربرد پردازش زبان طبیعی در مهندسی نیازمندی‌ها. با توجه به تداخلات بین NLP و ML، این تحقیق را به عنوان یکی از کارهای مرتبط برای تحلیل می‌پذیریم.

۲.۱.۲ بخشی از فرآیند مهندسی نیازمندی‌ها

در فرآیند استخراج نیازمندی‌ها، Sampada G.C. و همکاران [۱۰] یک نگاه کلی از رویکردهای مختلف برای اتوماسیون استخراج و مشخصه‌گذاری نیازمندی‌ها در چرخه توسعه نرم‌افزار ارائه دادند. Lim و همکاران [۴] وضعیت فعلی روش‌های پیشروی استخراج نیازمندی‌های مبتنی بر داده از منابع داده پویا را بررسی کردند و شکاف‌های تحقیق را شناسایی کردند. Cheliger و همکاران [۱۱] با انتخاب ۸۶ مقاله، مطالعاتی را که فناوری‌های ML و NLP را در استخراج نیازمندی‌ها شامل می‌شوند، خلاصه و تحلیل کردند. آن‌ها تکنیک‌های مختلف برای ساخت روش‌های استخراج نیازمندی مبتنی بر ML را به پنج بخش دسته‌بندی کردند.

در فرآیند طبقه‌بندی نیازمندی‌ها، Alrumaih و همکاران [۱۲] به بررسی مطالعات تحقیقی در زمینه طبقه‌بندی نیازمندی‌ها پرداختند و محدودیت‌ها را بررسی کردند تا پیشنهادها را بهبودی ارائه دهند. Perez و همکاران [۱۳] کاربردهای تکنیک‌های ML در طبقه‌بندی نیازمندی‌های نرم‌افزار را بر اساس ۱۳ مقاله بررسی کردند و الگوریتم‌های طبقه‌بندی مکررترین و مجموعه داده‌های آموزشی مکررترین را خلاصه کردند. Khelifa و همکاران [۱۴] بررسی کردند که آیا تکنیک‌های یادگیری ماشین در طبقه‌بندی نیازمندی‌ها نرم‌افزاری و طبقه‌بندی درخواست‌های تغییرات نیازمندی‌ها قابل اعمال هستند. به علاوه، Kadebu و همکاران [۱۵] بر روی مهندسی نیازمندی‌های امنیتی تمرکز کردند و کاربردهای تکنیک‌های ML در استخراج و طبقه‌بندی نیازمندی‌های امنیتی را بررسی کردند.

در فرآیند مدیریت نیازمندی‌ها، Xu و همکاران [۱۶] هشت روش ML را که در مدیریت نیازمندی‌ها استفاده شده است خلاصه کردند و ۱۸ شاخص ارزیابی برای مدیریت نیازمندی‌ها در روش ML مشخص کردند. کار آن‌ها به عنوان یک درک اولیه از گستره وسیعی از تکنیک‌های ML در مدیریت نیازمندی‌ها خدمت می‌کند، در حالی که برخی مطالعات به تفصیل به وظایف خاص می‌پردازند.

Achimugu و همکاران [۱۷] به بررسی تکنیک‌های اولویت‌بندی نیازمندی‌های نرم‌افزار از طریق ۷۳ مقاله مرتبط پرداختند و چندین محدودیت در تکنیک‌های اولویت‌بندی موجود را مورد بررسی قرار دادند. به علاوه، Li و همکاران [۱۸] با انجام یک مطالعه نگاشت سیستماتیک با ۲۶ مطالعه، ۳۲ فناوری ML برای پیگیری نیازمندی‌ها را خلاصه کردند. از مطالب فوق مشخص است که تعداد زیادی از بررسی‌های ادبیات عالی در زمینه MFLRE وجود دارد. با این حال، در حال حاضر، کمبودی در تحقیقات وجود دارد که ادغام بخش خاکستری را که نماینده جنبه‌های صنعتی است، در نظر بگیرد. هدف کار ما پر کردن این شکاف است با جامع نگاه داشتن به دیدگاه‌های دانشگاهی و صنعتی.

۲.۲ بررسی‌های ادبیات در مهندسی نرم‌افزار

در زمینه مهندسی نرم‌افزار، تعداد زیادی بررسی ادبیات سیستماتیک وجود دارد. ما مقالات مرتبطی را که شامل ادبیات خاکستری هستند انتخاب کرده‌ایم. آن‌ها را بر اساس سه حوزه موضوعی دسته‌بندی کرده‌ایم که هرکدام به ترتیب معرفی می‌شوند:

۱.۲.۲ منابع متدولوژی‌های توسعه نرم‌افزار

منابع متدولوژی‌های توسعه نرم‌افزار به مدل‌ها یا سیستم‌های ارزش‌گذاری مهندسی نرم‌افزار است که توسط توسعه‌دهندگان گسترده در فرآیند توسعه نرم‌افزار پذیرفته می‌شود. متدولوژی‌های معروف در توسعه نرم‌افزار شامل، DevOps Agile و DevSecOps است که بر اساس آخرین مورد بر اساس DevOps بررسی می‌شود. França و همکاران [۱۹] یک بررسی ادبیات انجام دادند با هدف توصیف DevOps از دیدگاه‌های مختلف. Amaro و همکاران [۲۰] به هدف روشن‌سازی قابلیت‌های DevOps و ارتباط آن‌ها با شیوه‌های عملیاتی DevOps پرداختند. با پیشرفت DevOps، امنیت برای مهندسی نرم‌افزار اهمیت بیشتری پیدا می‌کند. DevSecOps با یکپارچگی روش‌های امنیتی مدرن و DevOps برای اجرای این امر به وجود آمده است. Myrbakken و Colomo-Palacios [۸] یک بررسی ادبیات انجام دادند تا یک دید کلی از تعریف، اهمیت، مزایا و چالش‌های DevSecOps ارائه دهند. برای کیفیت پیاده‌سازی، Prates DevSecOps و همکاران [۲۱] یک بررسی ادبیات انجام دادند تا معیارهایی که تیم‌ها می‌توانند برای اندازه‌گیری کارایی پیاده‌سازی متدولوژی DevSecOps در سازمان‌ها استفاده کنند، شناسایی کنند. بیشتر و بیشتر شرکت‌های IT به معماری خدمات میکرو بازیافته تا کسب و کار خود را ارائه دهند. Soldani و همکاران [۲۲] ادبیات خاکستری صنعتی را درباره دردها و سودهای معماری میکروسرویس‌ها به صورت سیستماتیک انتخاب و تجزیه و تحلیل کردند. Bhandari و Colomo-Palacios [۲۳] بر روی هولاکراسی برای تیم‌های توسعه نرم‌افزار تمرکز کردند. برخی از اعمال به اینکه چگونه از ML برای کمک به DevOps در توسعه استفاده می‌شود. Recupito [۲۴] یک بررسی ادبیات چند صداگذاری انجام داد تا ابزارهای MLOps و قابلیت‌های آنها در خودکارسازی لوله‌های یادگیری ماشین با شیوه‌های عملیاتی DevOps را بررسی کند.

۲.۲.۲ مهندسی نرم‌افزار عمومی

بعضی از تحقیقات به ادغام صداهای حرفه‌ایان در حوزه گسترده‌تر مهندسی نرم‌افزار متمرکز شده‌اند. Kamei و همکاران [۲۵] یک مطالعه سومی انجام دادند تا درکی از استفاده تحقیقات ثانویه از ادبیات خاکستری به دست آورند. با توجه به وضعیت محققان در مهندسی نرم‌افزار که هنوز با ارتباط کم تحقیقات با نیازهای حرفه‌ایان درگیر بودند، Garousi و همکاران [۲۶] یک بررسی ادبیات انجام دادند. آن‌ها درک‌هایی از علل کم‌ارتباطی و پیشنهادهایی برای بهبود آن را به دست آوردند. Rainer و Williams [۲۷] یک مطالعه سومی را در مورد تحقیقات به شیوه‌های عملی نرم‌افزاری با استفاده از اسناد شبیه به وبلاگ انجام دادند. Alves و همکاران [۲۸] یک طبقه‌بندی جامع از شیوه‌های استفاده شده در صنعت برای ساخت سیستم‌های یادگیری ماشین ارائه دادند، که برای سازمان‌ها برای بهبود و مدیریت فرآیندها و شیوه‌های ML آموزنده است. Heiland و همکاران [۲۹] یک دیدگاه کلی از الگوهای طراحی برای سیستم‌های مبتنی بر هوش مصنوعی ارائه دادند، که شامل الگوهای جدید و تطبیق‌یافته است، جمع‌آوری شده از طریق یک بررسی ادبیات چند صداگذاری.

۳.۲.۲ بخش‌های خاص در مهندسی نرم‌افزار

بررسی‌های ادبیات در بخش‌های مختلف مهندسی نرم‌افزار وجود دارد. در حوزه آزمون نرم‌افزار، Raulamo-Jurvanen و همکاران [۳۰] یک بررسی ادبیات خاکستری انجام دادند تا مشکلات پتانسیلی فرآیندهای موجود و فرصت‌های ارزیابی جامع ابزار را شناسایی کنند. برای خودکارسازی آزمون، Garousi و Mäntylä [۷] بررسی ادبیاتی در مورد زمان و چه چیزی را باید در آزمون نرم‌افزار خودکارسازی کردند. Garousi و همکاران [۳۱] بر روی ارزیابی رشد آزمون و بهبود فرآیند آزمون تمرکز داشتند و بررسی ادبیاتی را انجام دادند. Garousi و Küçük [۳۲] یک نقشه‌برداری ادبیات چند صداگذاری را در مورد بوی‌های آزمون در هر دو ادبیات علمی و خاکستری انجام دادند. Garousi و Felderer [۳۳] آزمون نرم‌افزار را در صنعت و دانشگاه مورد بررسی قرار دادند و پیشنهادات خود را درباره بهبود ارتباط و همکاری بین صنعت و دانشگاه در آزمون نرم‌افزار ارائه دادند. در حوزه مهندسی نیازها، Tripathi و همکاران [۳۴] از بررسی ادبیات برای یافتن ادبیات علمی و خاکستری استفاده کردند. آن‌ها بررسی کردند که چگونه استراتژهای نرم‌افزاری از استخراج نیاز، مستندسازی، اولویت‌بندی و اعتبارسنجی نیاز استفاده می‌کنند. به طور کلی، در منظر علمی مهندسی نرم‌افزار، توسعه‌های قابل توجهی در بررسی‌های ادبیات سیستماتیک دیده شده است، با انجام اعمال بسیار عالی که چشم‌اندازهای ادبیات

خاکستری را برای تحلیل ترکیب می‌کنند. با این حال، تحلیل ما نشان می‌دهد که از بین این اعمال، هنوز به تفکیک در MLFRE پرداخته نشده است، در حالی که کار ما این نقطه را پر می‌کند.

۳ پروتکل تحقیقاتی

ما از ساختار استاندارد پروتکل مطالعه نقشه‌برداری سیستماتیک در مهندسی نرم‌افزار که توسط Kitchenham و همکاران [۳۵] توسعه داده شده است، استفاده کردیم. مطالعه ما شامل دو بخش سفید و خاکستری بود، که هر کدام به صورت جداگانه بررسی شدند. سپس بخش مشترکی را توسعه دادیم تا یافته‌ها را از هر دو بخش یکی کنیم.

۱.۳ هدف‌ها و پرسش‌های تحقیق

به طور خاص، ما از روش Goal-Question-Metric [۳۶] استفاده کرده‌ایم. اهداف ما شامل بررسی دقیق منظر فعلی تحقیقات MLFRE می‌شود. علاوه بر این، ما به بررسی نیازهای عملی در مهندسی نیازها و روش‌های ML که از ادبیات خاکستری استخراج شده‌اند علاقه‌مندیم. در نهایت، ما تمرکز داریم بر مقایسه تمرکز تحقیقات دانشگاهی در دامنه مشکل و روش‌های استفاده شده در دامنه حل مسئله با شیوه‌های عملی در Stack Overflow. این اهداف منجر به فرمول‌بندی پرسش‌های تحقیقی (RQ) زیر می‌شود:

• RQ1: وضعیت فعلی تحقیقات دانشگاهی در MLFRE چیست؟

• RQ2: وضعیت فعلی کاربردهای MLFRE در Stack Overflow چیست؟

• RQ3: چگونه دیدگاه‌های Stack Overflow درباره MLFRE با یافته‌های تحقیقات دانشگاهی همخوانی دارند یا از آنها متفاوت هستند؟

برای پاسخ به این، RQها ما یک سری برچسب‌ها به عنوان معیارها تعریف می‌کنیم تا داده‌ها یا اطلاعاتی که باید از مقالات استخراج شود را مشخص کنیم. در بخش‌های بعدی، جزئیات فرآیند جستجوی ادبیات برای بخش‌های سفید و خاکستری را شرح می‌دهیم. همچنین معیارهای استفاده شده برای پاسخ به RQها و فرآیند استخراج و ترکیب داده را توضیح می‌دهیم.

۲.۳ فرآیند انتخاب بخش سفید

Fig. ۱ نشان دهنده روند فرآیند انتخاب در بخش سفید است، و تعداد مقالات استخراج شده در هر مرحله نیز در شکل آمده است. زیربخش‌های زیر جزئیات هر مرحله را ارائه می‌دهند.

۱.۲.۳ جستجوی سیستماتیک

ما جستجوی سیستماتیک بخش سفید خود را با استفاده از رشته جستجوی پیش‌تعریف شده در چهار پایگاه داده علمی انجام می‌دهیم. فرآیند جستجوی سیستماتیک در بخش سفید شامل سه مرحله است. ما هر مرحله را به ترتیبی که در شکل ۱ نشان داده شده است، توضیح می‌دهیم. انتخاب منابع جستجو. منابع جستجو می‌توانند به طور قابل توجهی کیفیت بررسی سیستماتیک ادبیات را تحت تأثیر قرار دهند. همانطور که توسط بسیاری از مطالعات پیشنهاد شده است [۳۵، ۳۷]، منابع جستجو باید شامل چندین پایگاه داده معتبر باشند. به طور خاص، ما چهار پایگاه داده علمی را انتخاب کرده‌ایم: SpringerLink Library، Digital ACM Xplore، IEEE و Scopus. این چهار پایگاه داده می‌توانند بیشتر از ادبیات مرتبط با مهندسی نیازها را پوشش دهند [۳۸].

تعریف رشته جستجو. موضوع اصلی مطالعه ما یادگیری ماشین برای مهندسی نیازها است. ما رشته جستجو را به دو بخش تقسیم کرده‌ایم: بخش مهندسی نیازها و بخش تکنیک‌های یادگیری ماشین. این دو بخش با استفاده از عملگر 'AND' به هم متصل شده‌اند. به طور خاص، هر بخش شامل اصطلاحات کلیدی مرتبط است و اصطلاحات کلیدی در هر بخش با استفاده از عملگر 'OR' به هم متصل شده‌اند. برای اطمینان از پوشش جستجوی جامع و کاهش تلاش‌های انتخاب دستی، چندین دوره انجام شد تا کلمات کلیدی تعیین و بهبود یابند. جزئیات کامل رشته‌های

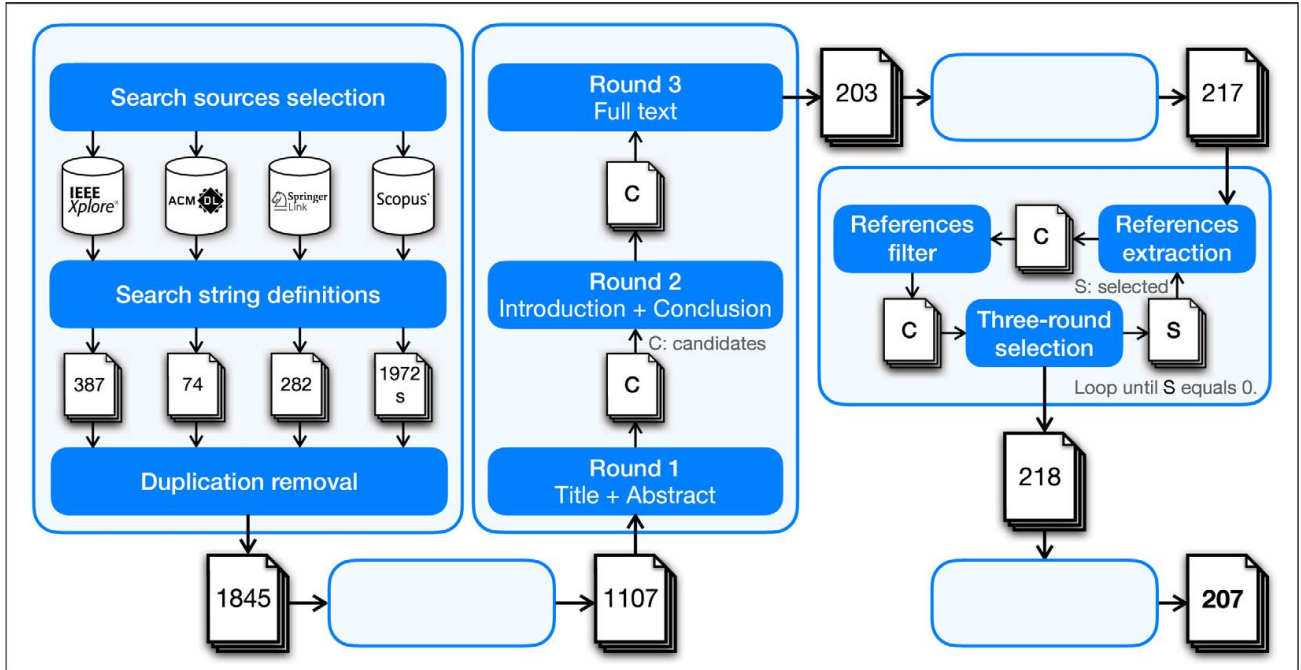


Table 1
The search string used in the white part.

Category	Keywords	
Requirements Engineering	requirements engineering	requirements specification
	requirements elicitation	requirements validation
	requirements analysis	requirements management
	software requirements	quality requirements
	functional requirements	non-functional requirements
Machine Learning	machine learning	semi-supervised learning
	machine-learning	deep learning
	supervised learning	reinforcement learning
	unsupervised learning	bayesian learning
	neural network	support vector machine
	decision tree	bayesian network

جستجو در جدول ۱ توضیح داده شده است. علاوه بر این، جستجوی snowballing در بخش ۵.۲.۳ برای گسترش دامنه جستجو به کار گرفته می‌شود.

حذف تکرار. ما برای پیدا کردن مقالاتی که عنوان، چکیده یا کلمات کلیدی آن‌ها شامل رشته جستجوی پیش‌تعریف شده در چهار پایگاه داده هستند و محدوده سال انتشار را بین سال‌های ۲۰۱۰ تا ۲۰۲۲ قرار داده‌ایم. مهم باید توجه داشت که SpringerLink فقط جستجوی متن کامل را پشتیبانی می‌کند، که نیازمند بررسی‌های اضافی در نتایج جستجوی این پایگاه داده است. به طور خاص، ما از توابع Sheets Google برای ادغام عنوان، چکیده و کلمات کلیدی هر مقاله استفاده کردیم و آن‌ها را با استفاده از عبارات منظم پیش‌تعریف شده با یکدیگر مطابقت دادیم. این فرآیند تعداد مقالات از ۷۳۶۷ مقاله در SpringerLink به ۲۸۲ مقاله کاهش داد. سپس، ما ۳۸۷ مقاله از IEEE، ۷۴ Xplore، ۱۸۴۵ مقاله از ACM، ۲۸۲ مقاله از SpringerLink و ۱۹۷۲ مقاله از Scopus به دست آوردیم. پس از حذف تمام تکرارها، تعداد ۱۸۴۵ مقاله باقی مانده است.

۲.۲.۳ فیلتر سیستماتیک

نتایج اولیه جستجو از موتورهای جستجوی علمی شامل موارد زیادی است که نمی‌خواهیم مانند سخنرانی‌های اصلی، پوسترها یا مقالاتی که بسیار کوتاه هستند. علاوه بر این، موتورهای جستجو مختلف جستجوی ما را در مقیاس‌های مختلف انجام می‌دهند، اگرچه تلاش کرده‌ایم جستجوی ما را به فیلدهای عنوان، چکیده و کلمات کلیدی محدود کنیم. بنابراین، سه معیار پیش از حذف (PEC) تعریف می‌کنیم تا این نوع مقالات را از بین ببریم و بار کاری بعدی را کاهش دهیم. به دلیل استفاده از Sheets Google برای ثبت مقالات، این معیارهای انحصاری ساده از طریق توابع به صورت خودکار قابل اعمال هستند. ارزش ذکر دارد که برای PEC^۳ از تطبیق regex برای عنوان، چکیده و کلمات کلیدی هر مقاله با رشته جستجوی تعریف شده استفاده کردیم. پس از فیلترینگ سیستماتیک، ۱۱۰۷ مقاله باقی مانده است.

• PEC^۱: طول مقاله کمتر از شش صفحه است.

• PEC^۲: مقاله به زبان انگلیسی نیست.

• PEC^۳: محتوای ترکیب شده عنوان، چکیده و کلمات کلیدی مقاله با رشته جستجوی تعریف شده مطابقت ندارد.

۳.۲.۳ انتخاب سه‌گانه

تمام مقالاتی که پس از فیلترینگ خودکار باقی مانده‌اند، سپس به صورت دستی بررسی می‌شوند تا از لحاظ ارتباط با موضوع مناسب بودند. معیار کلی انتخابی که ما تعریف کرده‌ایم این است که مقاله باید یک روش را پیشنهاد دهد که به طور اصلی از یادگیری ماشین برای کمک به وظایف مرتبط با مهندسی نیازها استفاده می‌کند.

معیارهای اضافه و حذف. برای بهبود اجرای معیار انتخابی، آن را به سری معیارهای اضافه و حذف (IC) و (EC) که در جدول ۲ نشان داده شده است، تجزیه و تحلیل کرده‌ایم. اگر مقاله با هریک از معیارهای حذف مطابقت داشته باشد، آن را حذف می‌کنیم؛ و تنها در صورتی که تمامی معیارهای اضافه را برآورده کند، آن را در می‌آوریم.

پروتکل انتخاب. دو نویسنده هر مقاله را از نظر معیارهای اضافه و حذف مورد بررسی قرار دادند. ابتدا مطالعه آزمایشی را بر روی ۴۰ مقاله به صورت تصادفی انجام دادیم. اگر نظرات مغایر وجود داشت، دو نویسنده نگرانی‌های خود را صریحاً بیان کرده و آن‌ها را حل کردند. از این مطالعه آزمایشی برای بهبود معیارهای ما استفاده کردیم و اجازه دادیم تا دو نویسنده بر جزییات عملی موافق شوند. پس از رسیدن به توافق در انتخاب مقالات، دو نویسنده مقالات باقیمانده را انتخاب کردند. اگر تضادی وجود داشت که دو نویسنده نتوانستند حل کنند، یک پژوهشگر سوم برای بررسی اضافی وارد می‌شد.

فرآیند انتخاب. همانطور که در شکل ۱ نشان داده شده است، ما فرآیند بازبینی دستی را به سه دور تقسیم کرده‌ایم. در دور ۱، بازبینان فقط عنوان و چکیده هر مقاله را می‌خوانند تا تصمیم بگیرند که آن را حذف یا حفظ کنند. تمام مقالات باقیمانده را به دور بعد منتقل می‌کنیم. در دور ۲، بازبینان هم عنوان و هم چکیده، مقدمه و نتیجه‌گیری هر مقاله را می‌خوانند. همانطور که قبلاً بود، این مقالات را تا دور بعد حفظ می‌کنیم، به جز مقالاتی که حذف شده‌اند. در دور ۳، بازبینان نیاز دارند که متن کامل را بخوانند و سپس تصمیم نهایی را بگیرند. پس از انجام سه دور انتخاب دستی، ما ۲۰۳ مقاله را انتخاب کردیم.

Table 2
Inclusion and exclusion criteria.

Aspects	Inclusion criteria	Exclusion criteria
Type	IC0 Original proposal	EC0 Empirical study, evaluation
Goal	IC1 The purpose of the paper is to improve the certain stage or activity of <i>Requirements Engineering</i>	EC1 The paper targets the general software engineering or the whole life cycle of software development rather than the <i>Requirements Engineering</i> specifically
Method	IC2 The main methods employed by the paper are <i>Machine Learning</i> techniques	EC2 The paper is about developing/designing <i>Machine Learning</i> applications/systems
Reviewed method	IC3 Peer-reviewed journal papers and conference & workshop papers	EC3 Non-peer-reviewed papers such as those published in magazines, notes, etc.

۴.۲.۳ افزایش دانش حوزه

در سال‌های اخیر، یادگیری ماشین به عنوان یک تکنیک گسترده، کاربردهای فراوانی در مهندسی نیازها داشته است. در طول این سال‌ها، تمرکز تحقیقات ما بر روی حوزه یادگیری ماشین برای مهندسی نیازها بوده است. به طور خاص، ما مقالات مربوطه را از جلسات معمولی مهندسی نیازها از جمله مجلات RE، REFSQ و AIRE از سال ۲۰۱۰ به بعد جمع‌آوری و خلاصه نموده‌ایم. ما این مقالات را از بین ۱۸۴۵ مقاله انتخاب نموده و به یک فرآیند انتخاب سه مرحله‌ای تحت آنها تحت‌پرسی کرده‌ایم. پس از این مرحله، ما مجموعاً ۲۱۷ مقاله را جمع‌آوری کرده‌ایم، که شامل ۱۴ مقاله جدید است.

۵.۲.۳ جستجوی برفی

برای افزایش جامعیت مطالعه خود، ما جستجوی برفی را با اسکن مراجع مقالات انتخاب شده از طریق روش قبلی انجام دادیم. استخراج مراجع: ما حدود ۹۰۰۰ مرجع را از تمامی ۲۱۷ مقاله در اولین دور جستجوی برفی خود استخراج کردیم. فیلتر مراجع: ابتدا ما به صورت خودکار و سیستماتیک ۹۰۰۰ مرجع را فیلتر کردیم. به طور خاص، ما مراجعی را که با رشته جستجوی مشخص شده در جدول ۱ همخوانی داشتند را انتخاب کردیم. پس از آن، ۲۴۴ مرجع انتخاب شد. پیش از استخراج عنوان مقالات از این مراجع به صورت دستی، تمامی مقالات قبل از سال ۲۰۱۰ و کمتر از شش صفحه را حذف کردیم. سپس مراجع تکراری را حذف نمودیم و ۱۰ مورد یکتا به عنوان نامزدهای مراحل بعدی باقی ماندند. انتخاب سه مرحله‌ای: این روند انتخاب سه مرحله‌ای همانند بخش ۳.۲.۳ است. پس از سه مرحله انتخاب، یک مقاله به تنهایی انتخاب شد و جستجوی برفی مکرر در این مقاله هیچ مقاله جدیدی تولید نکرد. به عبارت دیگر، پس از جستجوی برفی، ما به جمع کل ۲۱۸ مقاله رسیدیم.

۶.۲.۳ شناسایی و فیلتر کارهای گسترده‌تر

ما متوجه شدیم که در ۲۱۸ مقاله، ۱۱ جفت ارتباط گسترده‌تری دارند. ما مقالات گسترده‌تر را به عنوان نتیجه‌ای از این کارهای تحقیقاتی در نظر گرفتیم. بنابراین، مقالات قبل از گسترش را از مجموعه ما حذف کردیم. در نهایت، در بخش سفید، مجموعه داده نهایی ما شامل ۲۰۷ مقاله است. ما این مقالات را با شماره‌های آنها در تحلیل بعدی شناسایی می‌کنیم.

۳.۳ فرایند انتخاب بخش خاکستری

شکل ۲ روند فرایند انتخاب در بخش خاکستری را نشان می‌دهد و تعداد سوال‌های به دست آمده در هر مرحله نیز در شکل قید شده است. در زیربخش‌های بعدی جزئیات هر یک از این مراحل آورده شده است.

۱.۳.۳ انتخاب منبع جستجو

بر اساس دسته‌بندی گاروسی و همکاران [۳۹]، Overflow Stack به عنوان یک منبع ادبیات خاکستری از رده دوم با اعتبار متوسط در نظر گرفته می‌شود که امکان تحلیل کمی را فراهم می‌آورد. ما Overflow Stack را به عنوان منبع داده در بخش خاکستری انتخاب کردیم به دلیل طبیعت قابل دسترس و قابل تحلیل آن.

Table 3

The tags used in the grey part.

Category	Keywords
RE tags	requirements, user stories, system requirements, requirements management, tweets, minimum requirements, user feedback, backlog, tfs, jira, ibm doors, ms word, cucumber, enterprise architect, ibm rational, fitness, mks integrity, rally, sysml, azure devops, trello, doxygen, confluence
ML tags	machine learning, supervised learning, nlp, unsupervised learning, neural network, decision tree, deep learning, svm, convolutional neural network, recurrent neural network, lstm, reinforcement learning, regression, word2vec, bert language model, tensorflow, pytorch, bayesian networks, scikit learn, transformer model, encoder decoder, named entity recognition, roberta language model, huggingface transformers, huggingface trainer, shap, lda, large language model, embedding, topic modeling, langchain, spacy3, spacy, vector search, seq2seq, distilbert, sentence transformers, artificial intelligence, gnn, openai api, mobilenet, pytorch lightning, tensorflow2.0, tensorflow lite, text classification, knn, kaggle, multiclass classification, streamlit, keras, tf.keras, text mining

ما مجموعاً ۲۳،۷۵۸،۲۹۲ سوال در Overflow Stack پیدا کردیم. برای شناسایی و فیلتر کردن سوال‌های مرتبط با مهندسی نیازمندی‌ها، از برچسب‌ها به عنوان ابزارهای دسته‌بندی استفاده کردیم. به طور خاص، شش برچسب زیر را انتخاب کردیم: user-stories، requirements، RTags و minimum-requirements، requirements-management، system-requirements، MLtags و MLtags در جدول ۳ ذکر شده است. سپس از Overflow Stack API استفاده کردیم تا تمام سوالاتی که دارای هر کدام از این برچسب‌ها از سال ۲۰۱۰ تا ۲۰۲۲ بودند، استخراج کنیم. این تلاش به تعداد سوال‌های متناظر زیر منجر شد: ۵۳۰، ۱۸۳، ۶۲، ۳۱، ۲۲ و ۷۶. حذف تکرار: در Overflow، Stack سوالات ممکن است با چندین برچسب مرتبط باشند و ممکن است بیش از یکی از برچسب‌های انتخاب شده ما را شامل شوند. پس از حذف تکرارها، تعداد ۸۶۱ سوال باقی مانده است.

۳.۳.۳ انتخاب دستی

تمرکز ما بر روی چالش‌های عملی مواجهه شده در مهندسی نیازمندی‌ها و استخراج نیازمندی‌های عملی از آن‌ها است. بنابراین، تمامی ۸۶۱ سوال که با موفقیت از فیلتر کردن بر اساس برچسب‌ها گذر کرده‌اند، به صورت دستی بررسی شده‌اند از نظر ارتباط با مهندسی نیازمندی‌ها. دو نویسنده هر سوال را بر اساس معیار انتخابی ارزیابی کرده‌اند. یک مطالعه پیلوت اولیه شامل ۵۰ سوال به صورت تصادفی انتخاب شده انجام شد تا نظرات متضاد را مورد بررسی قرار دهد و به نویسندگان کمک کند تا به توافق برسند. سپس، دو نویسنده سایر سوالات را ارزیابی کردند. در نهایت، ۳۷۵ سوال برای بخش خاکستری انتخاب شدند.

۴.۳ استخراج داده و ترکیب آنها

این بخش شرح فرآیندهای استخراج داده و سنتز آنها برای بخش‌های سفید، خاکستری و مشترک را ارائه می‌دهد. ما یک مجموعه از برچسب‌ها را شناسایی کردیم که اطلاعاتی که باید از نتایج جستجو استخراج شود به عنوان معیارها عمل می‌کنند، با هدف پاسخگویی به سوالات تحقیقاتی براساس اطلاعات به دست آمده.

۱.۴.۳ استخراج و ترکیب داده‌های سفید

برای پاسخ به سوال تحقیق شماره ۱، (RQ1) قصد داریم چهار جنبه اطلاعات را از مقالات استخراج کنیم که هرکدام شامل مجموعه‌ای از برچسب‌ها است که در شکل ۳ نشان داده شده است. توضیحات این چهار جنبه و برچسب‌های مربوط به آنها به شرح زیر است:

۱. اطلاعات اولیه

(I) این جنبه به درک وضعیت ابتدایی مقالات می‌پردازد و شامل چهار برچسب زیر است:

i. سال‌های انتشار

ii. انواع انتشارات

iii. محل‌های انتشار

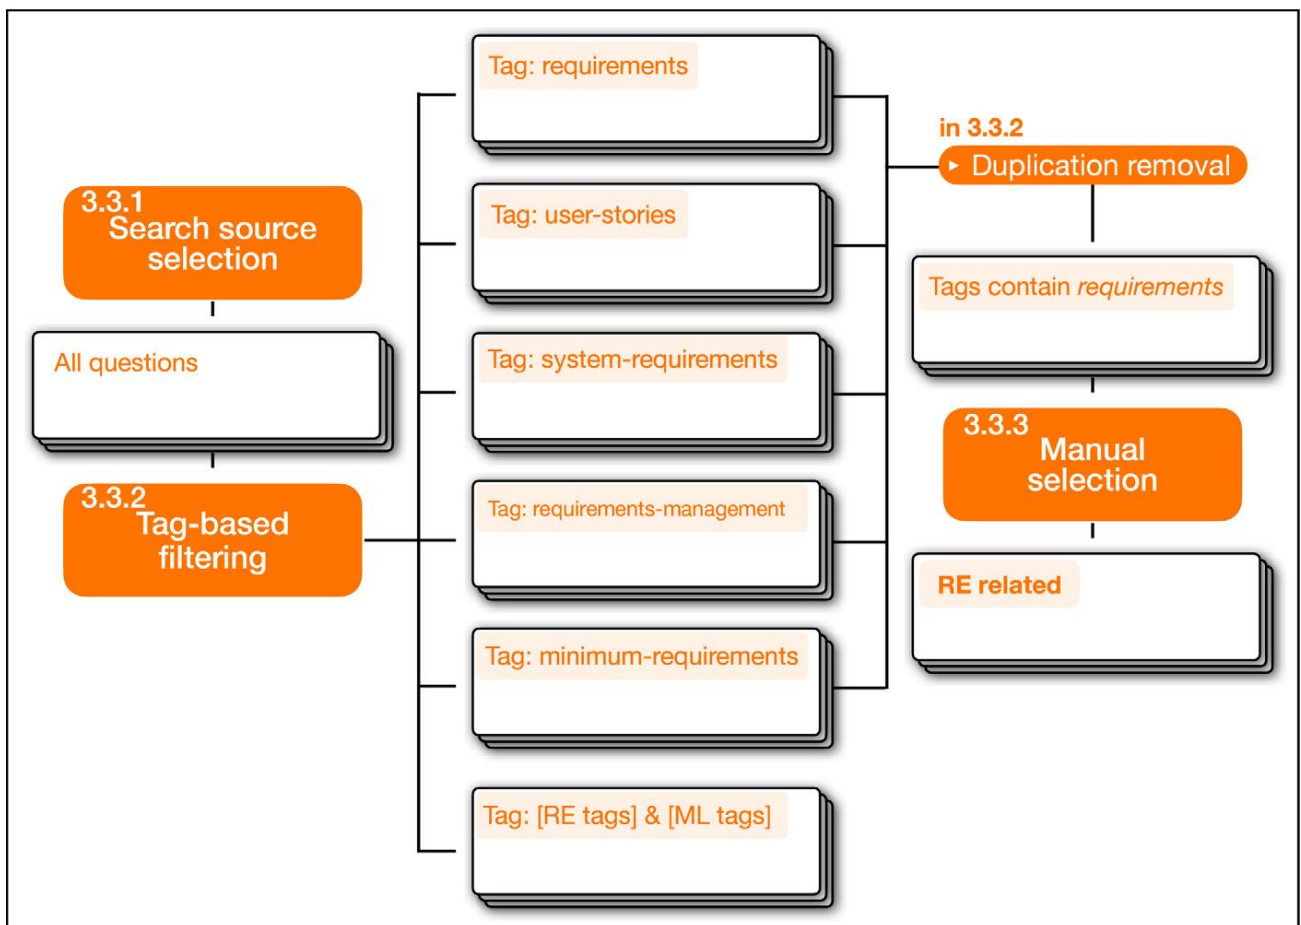
iv. ارجاعات (Citations)

۲. حوزه مسئله:

• این جنبه به درک تمرکز جامعه علمی بر مهندسی نیازمندی‌ها می‌پردازد و شامل دو برچسب زیر است:

– فعالیت‌های مهندسی نیازمندی‌ها (RE activities)

– وظایف مهندسی نیازمندی‌ها (RE tasks). برای فعالیت‌های مهندسی نیازمندی‌ها، مطابق با دانش نرم‌افزاری (SWEBOOK) هر مقاله را به یکی از پنج فعالیت زیر دسته‌بندی می‌کنیم: استخراج نیازمندی‌ها، تجزیه و تحلیل نیازمندی‌ها، مشخصه‌سازی نیازمندی‌ها، اعتبارسنجی نیازمندی‌ها و مدیریت نیازمندی‌ها. برای وظایف مهندسی نیازمندی‌ها، وظایف خاص مهندسی نیازمندی‌ها از هر مقاله استخراج می‌شود بر اساس توضیحات آن.



- این جنبه به بررسی استفاده از روش‌های یادگیری ماشین در ML۴RE (یادگیری ماشین برای مهندسی نیازمندی‌ها) می‌پردازد و شامل سه برچسب زیر است:

- وظایف ML ML (tasks)
- تکنیک‌های ML ML (techniques)
- ابزارهای ML ML (tools). برای وظایف ML، انواع وظایف ML از هر مقاله استخراج می‌شود مانند طبقه‌بندی و خوشه‌بندی. سپس، تکنیک‌ها و ابزارهای خاص ML استخراج می‌شود که در هر مقاله استفاده شده‌اند. برای قابلیت تکرار، انواع مواد قابل تکرار ارائه شده در هر مقاله مانند داده، کدهای مدل و نمایش‌های آزمایش ثبت می‌شود.

۴. داده:

- این جنبه به مطالعه داده‌های تجزیه و تحلیل شده در ML۴RE می‌پردازد و شامل دو برچسب زیر است:

- انواع داده‌ها (Data types)
- منابع داده (Data sources). برای انواع داده‌ها، ابتدا داده‌ها را به چهار نوع عمومی دسته‌بندی می‌کنیم و سپس داده‌های خاص بر اساس محتوای مقاله ثبت می‌شود. چهار نوع عمومی داده عبارتند از: آثار نیازمندی، نظرات کاربران، داده‌های دامنه و آثار در مهندسی نرم‌افزار. (SE) برای منابع داده، آنها را به یکی از پنج دسته زیر دسته‌بندی می‌کنیم: عمومی، به دست آمده، خصوصی، اصلی و بدون ذکر. همچنین، منابع داده خاص استخراج می‌شود.

۵. مدل:

- این جنبه به بررسی مدل‌های استفاده شده در ML۴RE می‌پردازد و شامل دو برچسب زیر است:

- انواع مدل‌ها (Model types)
- روش‌های ارزیابی مدل‌ها (Model evaluation). methods). برای انواع مدل‌ها، انواع مدل‌های استفاده شده در هر مقاله مانند شبکه‌های عصبی مصنوعی، درخت تصمیم، رگرسیون و ... ثبت می‌شود. برای روش‌های ارزیابی مدل‌ها، روش‌های مختلفی مانند دقت، بازخوانی، دقت و بازخوانی متوازن، ماتریس درهم‌ریختگی و ... مورد بررسی قرار می‌گیرد.

این جنبه‌ها و برچسب‌ها به عنوان معیارها برای تجزیه و تحلیل سیستماتیک اطلاعات به دست آمده از مقالات استفاده می‌شوند تا به پاسخگویی به سوالات تحقیقی بپردازیم.

۲.۴.۳ استخراج و سنتز داده‌های خاکستری

برای پاسخ به سوال تحقیق شماره ۲، (RQ۲) طراحی شده است که چهار جنبه اطلاعات را از سوالات و پاسخ‌ها استخراج کنیم، هرکدام شامل مجموعه‌ای از برچسب‌ها هستند که در شکل ۴ نشان داده شده است. توضیحات این چهار جنبه و برچسب‌های مربوط به آنها به شرح زیر است:

۱. اطلاعات اولیه:

- این جنبه به درک وضعیت ابتدایی سوالات می‌پردازد، شامل چهار برچسب زیر است:

- سال‌های ارسال
- انواع سوالات
- وضعیت سوال
- تعداد پاسخ‌ها. برای انواع سوالات، بر اساس محتوا، سوالات را به پنج نوع دسته‌بندی می‌کنیم: تعریف‌های مفهومی، روش‌های عملی در عمل، مشکلات خاص در عمل مهندسی نیازمندی‌ها، مشکلات در استفاده از ابزار و نیاز به راه‌حل‌ها. برای وضعیت سوال، ثبت می‌کنیم که آیا پرسش کننده سوال پاسخ را قبول کرده است یا خیر.

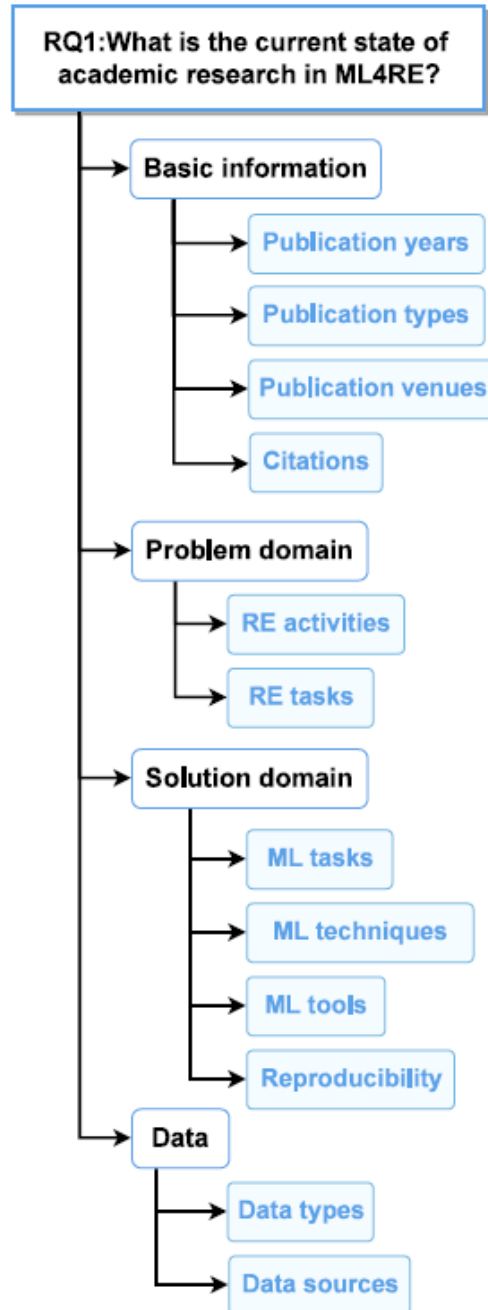


Fig. 3. Tags in the white part.

۲. حوزه مسئله:

- این جنبه به مطالعه چالش‌های عملی مهندسی نیازمندی‌ها که در جامعه Overflow Stack مواجه می‌شوند می‌پردازد، شامل دو برچسب زیر است:

- فعالیت‌های مهندسی نیازمندی‌ها (RE activities)
- وظایف مهندسی نیازمندی‌ها (RE tasks). مشابه بخش سفید، هر سوال را بر اساس SWEBOOK به یکی از پنج فعالیت مهندسی نیازمندی‌ها دسته‌بندی می‌کنیم. علاوه بر این، وظایف شناسایی شده در بخش سفید را در زمان تعیین وظایف RE به سوالات در نظر می‌گیریم.

۳. حوزه راه‌حل:

- این جنبه به بررسی استفاده از ابزارها در جامعه Overflow Stack می‌پردازد، شامل دو برچسب زیر است:
- ابزارها (Tools)
- یادگیری ماشین (ML). ما ابزارهای مهندسی نیازمندی‌ها مطرح شده در سوالات و پاسخ‌ها را جداگانه ثبت می‌کنیم. برای ML، اطلاعات مربوط به ML را بر اساس فرآیند در بخش سفید استخراج می‌کنیم.

۴. داده:

- این جنبه به مطالعه داده‌های تجزیه و تحلیل شده در جامعه Overflow Stack می‌پردازد، شامل تنها یک برچسب زیر است:
- انواع داده‌ها (Data types). ابتدا انواع خاص داده‌های پردازش شده در هر سوال را ثبت می‌کنیم. سپس، همه انواع داده‌های خاص را به دسته‌های داده‌های کلی‌تری که در بخش سفید استفاده شده‌اند، گروه‌بندی می‌کنیم.

۳.۴.۳ ترکیب و تحلیل داده‌ها به صورت مشترک

- برای پاسخ به سوال تحقیق شماره ۳، (RQ۳) قصد داریم چهار جنبه اطلاعات را از بخش سفید و بخش خاکستری مقایسه کنیم، هرکدام شامل مجموعه‌ای از برچسب‌ها که در شکل ۵ نشان داده شده است. توضیحات این چهار جنبه و برچسب‌های مربوط به آنها به شرح زیر است:

۱. اطلاعات اولیه:

- این جنبه برای مقایسه وضعیت ابتدایی بین تحقیقات علمی و کاربردهای عملی در Overflow Stack طراحی شده است، شامل یک برچسب زیر است:
- Trend (روند). به طور خاص، روند برای تمایز دادن تمرکز دانشگاهی و عملیاتی در Overflow Stack با مقایسه سال‌های انتشار در بخش سفید و سال‌های ارسال در بخش خاکستری مورد استفاده قرار می‌گیرد.

۲. حوزه مسئله:

- این جنبه برای مقایسه تاکید بر مهندسی نیازمندی‌ها بین دو بخش طراحی شده است، شامل دو برچسب زیر است:
- فعالیت‌های مهندسی نیازمندی‌ها (RE activities)
- وظایف مهندسی نیازمندی‌ها (RE tasks). ما مقایسه‌ای بر اساس فعالیت‌های وظایف RE استخراج شده در بخش سفید و خاکستری انجام می‌دهیم.

۳. حوزه راه‌حل:

- این جنبه برای مقایسه روش‌های استفاده شده توسط دانشگاه و عملیات در Overflow Stack در حل مشکلات مهندسی نیازمندی‌ها طراحی شده است، شامل یک برچسب زیر است:

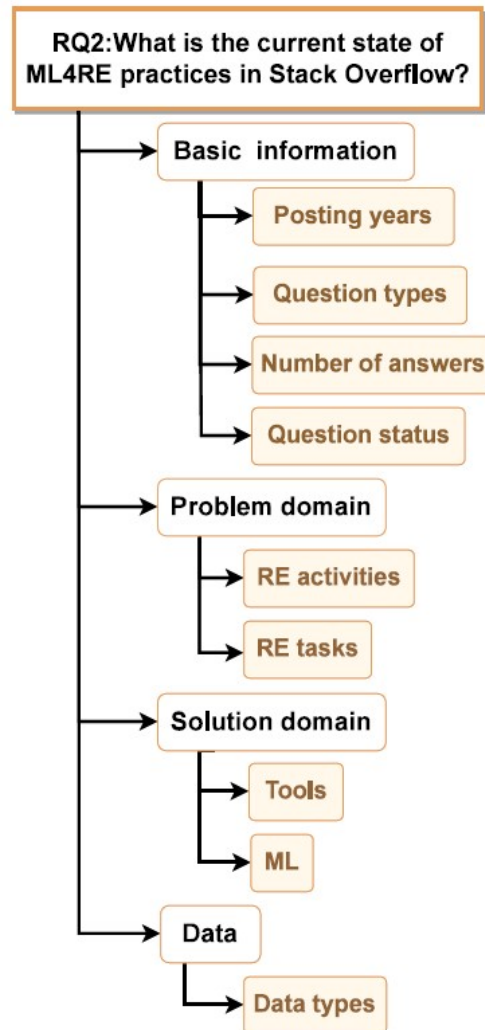


Fig. 4. Tags in the grey part.

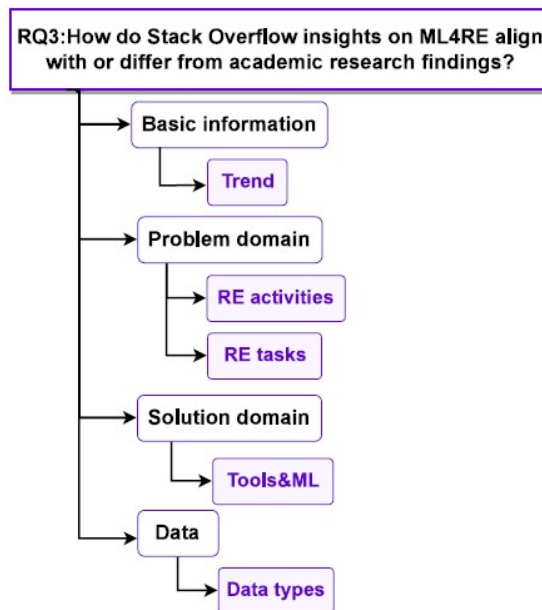


Fig. 5. Tags in the joint analysis part.

– ابزارها و ML. (Tools&ML) ما این مقایسه را بر اساس تکنیک‌های ML استخراج شده در بخش سفید در مقابل ابزارها و ML در بخش خاکستری انجام می‌دهیم.

۴. داده:

• این جنبه برای مقایسه داده‌های مورد بررسی در تحقیقات علمی با انواع داده‌های مورد بحث و تجزیه و تحلیل در جامعه Stack Overflow طراحی شده است، شامل یک برچسب زیر است:

– انواع داده‌ها (Data types). (Data types) مقایسه بر اساس انواع داده استخراج شده در بخش سفید و خاکستری صورت می‌پذیرد.

مانند انتخاب دستی قبلی، دو پژوهشگر برای هر مقاله به منظور انجام پردازش داده تعیین شده‌اند تا اعتبار پژوهش‌ها تضمین شود.

۴ نتایج بخش سفید (RQ1)

با پیروی از طراحی در بخش ۱.۴.۳، اطلاعات استخراج شده از مقالات برای پاسخ به سوال پژوهشی ۱ (RQ1) را با برخی از نمودارهای دقیقاً طراحی شده، همانطور که در منبع [۳۷] توصیه شده است، ارائه می‌دهیم.

۱.۴ اطلاعات پایه

در این زیر بخش، ما برخی اطلاعات پایه را برای درک وضعیت در جامعه علمی ارائه می‌دهیم.

۱.۱.۴ سال‌های انتشار

در بخش سفید، ما ۲۰۷ مقاله را انتخاب کرده‌ایم. شکل ۶ تعداد مقالات در مورد ML4RE را در هر سال از ۲۰۱۰ تا ۲۰۲۲ نشان می‌دهد. همانطور که در شکل می‌بینیم، تحقیقات در این زمینه طی دهه گذشته به صورت تابع درجه دوم رشد کرده است و تعداد مقالات از سال ۲۰۱۶ به طور قابل توجهی افزایش یافته است. برای تسهیل بحث‌های بعدی، ما به طور موقت ۱۳ سال گذشته را به دو مرحله تقسیم می‌کنیم: مرحله اولیه (۲۰۱۵–۲۰۱۰) و مرحله توسعه (۲۰۲۲–۲۰۱۶).




Fig. 6. The number of papers on ML4RE per year from 2010 to 2022.



Fig. 7. Number of papers per year in each types.

۲.۱.۴ انواع انتشارات

در مقالاتی که انتخاب کرده‌ایم، ۱۱۵ مقاله کنفرانس، ۶۶ مقاله ژورنال و ۲۶ مقاله کارگاهی وجود دارد. تعداد هر نوع مقاله در هر سال در شکل ۷ است. به طور خاص، تعداد مقالات کنفرانسی در چهار سال اول (۲۰۱۶-۲۰۱۹) پس از ورود به فاز توسعه، به سرعت افزایش یافت. با گذشت زمان و تجمع کارهای تحقیقاتی، تعداد مقالات ژورنالی از سال ۲۰۲۰ آغاز به افزایش یافت. در پنج سال قبل از سال ۲۰۲۰، میانگین تعداد مقالات ژورنالی تنها ۶.۴ مقاله بر سال بود. با این حال، تنها در سال ۲۰۲۰، ۱۳ مقاله ژورنالی در این حوزه منتشر شد. در سال ۲۰۲۲، آن‌ها ۱۷ مقاله ژورنالی منتشر کردند و به اوج جدیدی رسیدند.

۳.۱.۴ محل‌های انتشار

پژوهشگران ۲۰۷ مقاله را که انتخاب کرده‌ایم، در ۱۲۹ محل انتشار منتشر کردند. جدول ۴، مروری از محل‌های انتشار را نشان می‌دهد، با دسته‌بندی محل‌هایی که تنها یکبار ظاهر شده‌اند به عنوان محل‌های دیگر. همان‌طور که جدول ۴ نشان می‌دهد، ۲۴ محل با چندین انتشار تقریباً نصف مقالات (۱۰۲ از ۲۰۷، ۴۹٪) را منتشر کرده‌اند. آن‌ها تقریباً همه محل‌های کلاسیک در جامعه توسعه الزامات هستند. مابقی ۱۰۵ مقاله در محل‌های گسترده‌ای ظاهر شده‌اند (۱۰۵ از ۲۰۷، ۵۰٪) که به اشتراک گذاری ML4RE را بیرون از اجتماع توسعه الزامات کمک می‌کند. در نظرسنجی ما، متوجه شدیم که ۱۶ مقاله به روابط گسترده اشاره دارند. جدول ۵ اطلاعات مربوط به این ۱۶ جفت مقاله با روابط گسترده را نشان می‌دهد. بیشتر آن‌ها مواردی هستند که یک مقاله کنفرانسی به یک مقاله ژورنالی گسترده شده است. به عنوان مثال، پنج مقاله ژورنالی از مقاله‌های کنفرانسی در سال ۲۰۲۰ گسترش یافتند. این نتیجه بیشتر نشان می‌دهد که مقالات ژورنال از تجمیع کارهای پژوهشی پیشین در زمینه ML4RE ناشی می‌شوند.

Table 4

Publication venues.

Paper type	Venue	Count
Journal papers	Appl. Sci.	4
	ESE	3
	IEEE Access	3
	IET Software	2
	IJACSA	2
	IST	4
	JSS	5
	REJ	7
	SQJ	2
	SoSyM	3
	TSE	3
	Others	28
Conference papers	APSEC	2
	ASE	3
	COMPSAC	2
	EASE	3
	ICIT	2
	ICSE	6
	MODELS	3
	RE	26
	SERA	2
	WorldCIST	2
	Others	64
Workshop papers	AIRE, co-located with RE	9
	RAISE, co-located with ICSE	2
	REW, co-located with RE	2
	Others	13

Table 5

Extended papers information.

No.	Before extension			After extension		
	Year	T	Venue	Year	T	Venue
1	2010	C	RE	2011	J	REJ
2	2015	C	RE	2015	J	REJ
3	2015	C	RE	2016	J	REJ
4	2017	C	RE	2017	J	REJ
5	2018	C	WI	2019	C	ICTAI
6	2018	C	APSEC	2020	J	JSS
7	2019	C	ICSR	2020	J	JSS
8	2019	C	REFSQ	2020	J	EMSE
9	2019	C	RE	2020	J	EMSE
10	2019	C	RE	2020	J	J SOFTW-EVOL PROC
11	2020	C	RE	2020	C	MODELS
12	2020	C	PoEM	2021	J	SoSyM
13	2018	C	RE	2021	J	ESE
14	2020	C	RE	2021	J	TSE
15	2021	C	RE	2022	J	PR
16	2020	C	RE	2022	J	RE


T = Type, C = Conference paper, J = Journal paper.

۴.۱.۴ نقل قول‌ها

ما روابط نقل قول بین مقاله‌های انتخابی را مستند کرده‌ایم، فراوانی هر مقاله که توسط کارهای دیگر انتخابی نقل قول شده است، را ثبت کرده‌ایم. در نهایت، ما مقالاتی را با بیشترین تعداد نقل قول شناسایی کرده‌ایم: P۰۵۳، P۰۵۲، P۰۲۲، P۰۱۴، P۰۱۸، P۰۴۰، P۰۵۸، P۰۲۳ و P۰۵۱. نقل قول‌های معتبری که این مقالات به دست آوردند با نقش نماینده آن‌ها در مراحل توسعه ایجاد شده‌اند. به ویژه، P۰۰۲ (۲۰۱۰) از تکنیک‌های بیزین نیو استفاده کرده است تا الزامات غیر تابعی را به صورت خودکار شناسایی و دسته‌بندی کند. مطالعات بعدی، به عنوان مثال، P۰۱۸، P۰۱۴، P۰۲۲ و P۰۲۳ (۲۰۱۳-۲۰۱۴)، به بررسی عمیق‌تر از استفاده از تکنیک‌های پردازش زبان طبیعی، مانند مدل‌سازی موضوع، پرداختند. در ادامه، P۰۴۰، P۰۵۳، P۰۵۸ و P۰۵۱ (۲۰۱۶-۲۰۱۷) تمرکز خود را به بهره‌گیری از یادگیری عمیق و استخراج متن برای تحلیل خودکار مجموعه داده‌های بزرگ منتقل کردند. در واقع، نقل قول‌های قابل توجه این مقالات ممکن است از نقش سازنده آن‌ها در گذاشتن اساس برای تحقیقات بعدی در هر مرحله ناشی شده باشد.

۲.۴ حوزه‌ی مسئله

در این زیربخش، تمرکز جامعه‌ی علمی بر روی انجام الزامات نرم‌افزار (RE) را ارائه می‌دهیم.



۱.۲.۴ فعالیت‌های RE

ما تعداد فعالیت‌های RE که توسط تکنیک‌های یادگیری ماشینی به آن‌ها کمک شده است، شمردیم. تجزیه و تحلیل الزامات فعالیت‌ها است که توسط تکنیک‌های یادگیری ماشینی بیشترین حمایت را دارد با تقریباً نیمی از مقالات (۹۰/۲۰۷، ۴۳٪۴۸). برای بقیه، تعدادی از جمع‌آوری و اعتبارسنجی الزامات مشابه است، ۵۹ برای اولی و ۳۶ برای دومی. آن‌ها در مجموع بیش از ۴۰٪ از کل ۲۰۷ مقاله‌ای انتخابی را تشکیل می‌دهند. در نهایت، ۲۲ تحقیق (۶۳٪۱۰) از تکنیک‌های یادگیری ماشینی در فاز مدیریت الزامات استفاده نمودند. در مقالات انتخابی ما، هیچ تحقیقی از تکنیک‌های یادگیری ماشینی برای مشخصات الزامات استفاده نکرد.

۲.۲.۴ وظایف RE

ما فعالیت‌ها و وظایف مربوط به RE را در شکل ۸ خلاصه می‌کنیم. ۲۰۷ مقاله بر روی ۴۲ وظیفه مختلف تمرکز داشتند. طبقه‌بندی نیازمندی‌ها (۴۳/۲۰۷، ۷۷٪۲۰) پرکارترین وظیفه در طول تحلیل نیازمندی و حتی در همه فعالیت‌های RE است. مدل‌سازی نیازمندی‌ها (۱۵، ۲۵٪۷)، استخراج و طبقه‌بندی نیازمندی‌ها (۹، ۳۵٪۴) و شناسایی نیازمندی‌ها (۶، ۹۰٪۲) نیز وظایف پرتعداد دیگری در فرایند تحلیل نیازمندی هستند. در مرحله جمع‌آوری، طبقه‌بندی بازخورد کاربر (۱۹، ۱۸٪۹)، استخراج ویژگی‌ها (۱۴، ۷۷٪۶) و استخراج نیازمندی‌ها (۱۱، ۳۲٪۵) وظایفی هستند که بیشترین توجه را جلب کرده‌اند. ارزیابی کیفیت نیازمندی‌ها (۱۴، ۷۶٪۶) و تشخیص ابهام در اسناد نیازمندی‌ها (۸، ۸۷٪۳) پرتعدادترین وظایف در طول فرآیند اعتبارسنجی نیازمندی هستند. در مدیریت نیازمندی، اولویت‌بندی نیازمندی‌ها (۹، ۳۵٪۴) و ردیابی نیازمندی‌ها (۹، ۳۵٪۴) متمرکز بر توجه پژوهشگران می‌باشند.

یازده وظیفه یاد شده بالا توجه بیشتری از سوی پژوهشگران در تمام مراحل RE جلب کرده‌اند. ۱۵۷ مقاله به این یازده وظیفه متناظر بوده‌اند که نمایانگر ۸۵٪۷۵ از کل (۱۵۷/۲۰۷) است. ارزشیابی کاری‌ها نشان می‌دهد که ۵۰ مقاله با ۳۱ وظیفه پژوهشی پراکنده در مراحل مختلف مهندسی نیازمندی روبرو شده‌اند. این داده‌ها نشان می‌دهند که تعداد زیادی (۳۱/۴۲، ۸۱٪۷۳) از وظایف RE در حوزه ML۴RE همچنان نیازمند بررسی بیشتر هستند.

۳.۴ دامنه راه‌حل

در این زیربخش، ما وضعیت تکنیک‌های یادگیری ماشینی مورد استفاده در حل مسائل مهندسی نیاز به نرم‌افزار ارائه می‌دهیم.

۱.۳.۴ وظایف یادگیری ماشینی

ما انواع وظایفی که تکنیک‌های یادگیری ماشینی هر سال پردازش می‌کنند را شمردیم که در شکل ۹ نشان داده شده است. آشکار است که طبقه‌بندی بخش قابل توجهی را تشکیل می‌دهد، در حالی که انواع دیگر وظایف سهم کمتری دارند.

۲.۳.۴ تکنیک‌های یادگیری ماشینی

در انتخاب ما از ۲۰۷ مقاله، پژوهشگران ۷۲ تکنیک یادگیری ماشینی مختلف را ۳۰۸ بار استفاده کردند. شکل ۱۰ رتبه‌بندی این تکنیک‌ها بر اساس تعداد استفاده‌ها را نشان می‌دهد. ما همه ۴۷ تکنیک یادگیری ماشینی که فقط یکبار استفاده شده‌اند را به عنوان «دیگران» دسته‌بندی می‌کنیم. پراستفاده‌ترین تکنیک یادگیری ماشینی SVM (۳۷ بار استفاده شده) است، در حالی که تکنیک‌های بعدی بیشتر استفاده شده شامل CNN (۲۰ بار)، درخت تصمیم (۱۷ بار)، BERT (۱۷ بار) و جنگل تصادفی (۱۵ بار) هستند. این داده‌ها یک روند مهم در استفاده از تکنیک‌های یادگیری ماشینی





Fig. 9. Types of tasks that ML techniques processed per year.



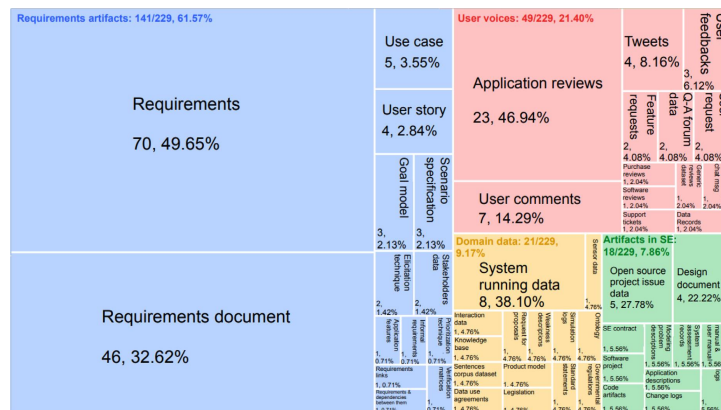
در مقالات یادگیری ماشین برای مهندسی نیاز به نرم‌افزار را نشان می‌دهند. استفاده بالا از روش‌های پیشرفته مانند BERT نشان دهنده تلاش مداوم پژوهشگران برای اکتشاف فناوری‌های روز دنیا است. علاوه بر این، از اثربخشی ادامه‌دار روش‌های سنتی یادگیری ماشین مانند Naive Bayes نشانه‌های معتبری مشخص است.

۳.۳.۴ ابزارهای یادگیری ماشین

بیش از نیمی از پژوهشگران (۱۲۳/۲۰۷) ابزارهای یادگیری ماشینی که در مقالات خود استفاده کرده‌اند را ذکر کرده‌اند، آن‌ها ۳۱ ابزار یادگیری ماشین را ۱۲۰ بار استفاده کرده‌اند. بیشتر ابزارهای یادگیری ماشین از جمله، scikit-learn، Weka، TensorFlow، Pytorch Keras و Matlab هستند.

۴.۳.۴ قابلیت تکرارپذیری

در زمینه بازتولید تحقیقات در حوزه ML۴RE، محققان مواد را در سه جنبه ارائه می‌دهند: داده‌ها، کدهای مدل و مصنوعات تجربی. نزدیک به ۳۷٪ (۷۷/۲۰۷) از مقالات حداقل یک ماده برای بازتولید ارائه کرده‌اند. بیشتر مواد بازتولید در داده‌ها یافت می‌شوند، پس از آن کدهای مدل و در نهایت مصنوعات تجربی. ما همچنین مواد ارائه شده در مقالات را مستند کرده‌ایم تا به محققان در دسترسی به منابع اضافی کمک کنیم.



۴.۴ داده‌ها

در این زیر بخش، وضعیت داده‌های حوزه RE پردازش شده توسط دانشگاه‌ها را معرفی می‌کنیم.

۱.۴.۴ انواع داده‌ها

با بررسی انواع داده‌های مورد استفاده توسط تکنیک‌های ML، ۵۳ نوع داده شناسایی شد و آنها را به چهار نوع کلی تقسیم کردیم، همانطور که در شکل ۱۱ نشان داده شده است. می‌بینیم که بیش از ۶۰٪ از داده‌ها در دسته مصنوعات نیازمندی‌ها قرار می‌گیرند، که این نوع داده‌ها بیشترین نیاز به پردازش برای حمایت از فعالیت‌ها و وظایف RE را دارند. از میان داده‌های باقی‌مانده، بیش از نیمی از آنها صدای کاربران را تشکیل می‌دهند و ۴۰.۲۱٪ از کل داده‌ها را شامل می‌شوند. این داده‌ها شامل بازخورد کاربران، درخواست‌ها و نقد و بررسی کاربران از نرم‌افزارها و برنامه‌ها، به همراه پیام‌هایی از انجمن‌های آنلاین و توییتر است. نقد و بررسی کاربران بخش عمده‌ای از صدای کاربران را تشکیل می‌دهد. داده‌های باقی‌مانده شامل مصنوعات در SE (۸۶٪.۷) و داده‌های حوزه‌ای (۱۷٪.۹) است. مصنوعات در SE شامل داده‌های چرخه حیات توسعه نرم‌افزار است. لازم به ذکر است که در اینجا مصنوعات در SE شامل مصنوعات نیازمندی‌ها نمی‌شود، زیرا آنها در دسته جداگانه‌ای به نام مصنوعات نیازمندی‌ها قرار دارند. داده‌های حوزه‌ای شامل ثروتی از دانش حوزه‌ای است و متنوع می‌باشد.

۲.۴.۴ منابع داده‌ها

ما منابع داده‌های استفاده شده را ثبت کردیم، همانطور که در شکل ۱۲ نشان داده شده است. شانزده مقاله در مورد منبع همه یا برخی از داده‌های استفاده شده مبهم بودند و به طور صریح منبع خاص داده‌ها را ذکر نکردند. در مرحله اولیه، مقالاتی که از داده‌های عمومی استفاده می‌کردند بیشتر از مقالاتی بودند که از داده‌های منابع دیگر استفاده می‌کردند. این غلبه داده‌های عمومی در مرحله توسعه نیز مشهود است. علاوه بر این، داده‌های خزیده شده و خصوصی از سال ۲۰۱۸ به بعد روند افزایشی واضحی نشان داده‌اند.

سپس، منبع خاص داده‌ها را به ترتیب داده‌های عمومی، خزیده شده، خصوصی و اصلی توصیف می‌کنیم.

داده‌های عمومی. ما داده‌های عمومی را به عنوان مجموعه داده‌هایی که به طور عمومی در دسترس هستند تعریف می‌کنیم. ما دریافتیم که ۷۶ مقاله از ۴۹ منبع داده عمومی ۱۰۳ بار استفاده کرده‌اند. چندین مجموعه داده عمومی کلاسیک به طور گسترده در حوزه MLFRE استفاده شده‌اند. به عنوان مثال، مجموعه داده PROMISE در ۲۵ مقاله استفاده شده است و آن را به پرکاربردترین مجموعه داده در میان مقالات منتخب ما تبدیل کرده است. علاوه بر این، چالش داده REIV در ۶ مقاله مورد استفاده قرار گرفته است. علاوه بر این‌ها، دیگر مجموعه داده‌های عمومی قابل توجه شامل PURE، RE@UTS iTrust، و tera-promise هستند.

داده‌های خزیده شده. ما داده‌های خزیده شده را به عنوان داده‌هایی که از طریق خزیدن وب به دست می‌آیند مشخص می‌کنیم. رایج‌ترین مکان برای خزیدن داده، فروشگاه‌های اپلیکیشن (۱۹/۵۸، ۸٪.۳۲) است، با فروشگاه گوگل پلی و فروشگاه اپل استور به عنوان منابع داده رایج. به دلیل توسعه سریع فروشگاه‌ها/بازارهای اپلیکیشن‌های موبایل، بسیاری از نقد و بررسی‌ها و توضیحات اپلیکیشن‌ها در دسترس بوده است که یکی از دلایل افزایش مقالات استفاده کننده از داده‌های خزیده شده در مرحله توسعه است.

داده‌های خصوصی. اگر یک مقاله به صراحت ذکر کرده باشد که داده‌هایشان از پروژه‌های صنعتی واقعی یا سایر سناریوهای عملی به دست آمده است، ما منبع داده را به عنوان عملی ثبت می‌کنیم. اگر محققان بگویند که داده‌هایشان از پروژه‌ها به دست آمده است، چنین منابع داده‌ای

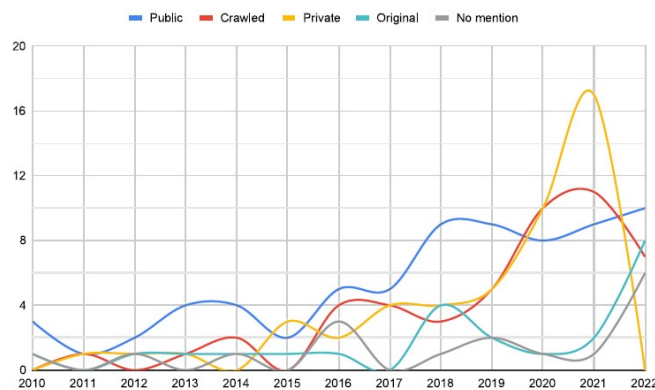


Fig. 12. All data sources by year.




Fig. 13. The number of questions on Stack Overflow per year from 2010 to 2022.

را به عنوان نوع پروژه ثبت می‌کنیم. بر اساس تحلیل ما، ۳۷ مقاله از داده‌های عملی استفاده کرده‌اند، ۱۲ مقاله از داده‌های پروژه‌ای استفاده کرده‌اند و ۴ مقاله منبع داده‌های خود را مشخص نکرده‌اند. داده‌های اصلی. ما داده‌هایی که متعلق به خود محققان است را به عنوان داده‌های اصلی تعریف می‌کنیم. به طور خاص، داده‌های اصلی می‌توانند از فرآیندهای اجرای سیستم به دست آیند یا از آزمایش‌ها جمع‌آوری شوند.

۳.۴.۴ وضعیت ML۴RE در دانشگاه‌ها

به طور خلاصه، چشم‌انداز کنونی تحقیقات ML۴RE نشان‌دهنده رشد مداوم در تعداد مقالات و حرکت به سمت انتشار در مجلات با کیفیت بالاتر است. در زمینه فعالیت‌های RE، تمرکز عمده‌ای بر تحلیل RE وجود دارد و طیف گسترده‌ای از وظایف خاص مورد بررسی قرار گرفته است. علاوه بر این، تکنیک‌های ML مانند CNN، SVM، درخت‌های تصمیم‌گیری و BERT به طور گسترده‌ای استفاده می‌شوند و برخی از کارها نیز مواد حمایتی برای پروژه‌های متن‌باز ارائه می‌دهند. انواع داده‌های مورد بررسی متنوع هستند و تأکید ویژه‌ای بر مصنوعات نیازمندی‌ها دارند، و منابع عمدتاً داده‌های عمومی هستند.